

Segmentação de texturas urbanas com um banco de filtros orientados em três escalas

Vitor Lorenzo Cumim¹

¹Universidade Federal do Paraná (UFPR) – Visão Computacional, Trabalho 1

vlc22@inf.ufpr.br

Abstract. *This work builds a 24-dimensional texture descriptor from a bank of seven filters — four even-phase Gabor filters oriented at 0, 45, 90 and 135 degrees, two odd-phase Gabor filters and one circular Laplacian of Gaussian — applied over three levels of a Gaussian pyramid. Each region is described by the mean filter response inside a window. A hand-written Euclidean k-means groups 40 grayscale crops of 512x512 pixels from eight urban materials, reaching a purity of 0.58 against the photographed material, and segments the interior of each image.*

Resumo. *Este trabalho monta um descritor de textura de 24 dimensões a partir de um banco de sete filtros — quatro Gabor de fase par nas orientações 0, 45, 90 e 135 graus, dois Gabor de fase ímpar e um filtro circular (Laplaciano da gaussiana) — aplicados em três escalas de uma pirâmide gaussiana. Cada região é descrita pela média das respostas dentro de uma janela. Um k-médias euclidiano escrito à mão agrupa 40 recortes de 512x512 pixels em tons de cinza, de oito materiais urbanos, com pureza de 0,58 em relação ao material fotografado, e segmenta o interior de cada imagem.*

1. Introdução

Duas regiões de uma imagem em tons de cinza podem ter exatamente o mesmo histograma e ainda assim serem visivelmente diferentes. Uma parede de tijolos e um trecho de asfalto podem ter o mesmo brilho médio, mas a parede tem linhas horizontais fortes e o asfalto não tem direção nenhuma. É essa diferença — como a intensidade varia no espaço, em que direção e em que tamanho — que chamamos de textura.

A estratégia clássica para medi-la é passar a imagem por filtros sintonizados em diferentes orientações e frequências e observar quanta energia cada um capta [Jain and Farrokhnia 1991, Randen and Husøy 1999]. Este trabalho segue essa receita, com filtros de Gabor [Gabor 1946] e um filtro circular, para agrupar 40 imagens por semelhança de textura e segmentar o interior de cada uma. Nenhuma etapa usa aprendizado de máquina: os filtros são fixos e projetados analiticamente, e o agrupamento é um k-médias euclidiano implementado diretamente. O código e as imagens estão em <https://github.com/vitorcumim/textura-urbana>.

2. Conjunto de imagens

O conjunto é de texturas urbanas: asfalto, brita, calçada, concreto, madeira, paralelepípedo, telha e tijolo — oito classes, cinco imagens cada, 40 imagens no total. As

fotos vieram do Wikimedia Commons, sob licenças livres, com autor e licença registrados no repositório; cabe a ressalva de que o enunciado pede fotos tiradas pelo próprio grupo, e estas não são. Foram baixadas 89 candidatas e todas passaram por curadoria visual, porque a busca textual do acervo é pouco confiável: pedir *asphalt texture* devolve cartas de ruído usadas para calibrar *scanners*.

Cada foto aprovada é convertida para tons de cinza pela fórmula da ITU-R BT.601, $Y = 0,299R + 0,587G + 0,114B$, e recortada em blocos de 512x512 tomados de uma grade centrada, sem sobreposição, de modo que dois recortes da mesma foto nunca compartilhem pixels.

3. O banco de filtros e as três escalas

Um filtro de Gabor é uma onda cosseno (ou seno) multiplicada por uma envoltória gaussiana, e responde forte onde a imagem tem variação periódica na orientação e no comprimento de onda para os quais foi sintonizado. Usou-se $\lambda = 5$ px, $\sigma = 2,2$ px, razão de aspecto $\gamma = 0,5$ e núcleo de 15x15 px. O banco tem sete filtros: quatro Gabor de **fase par** (cosseno) a 0, 45, 90 e 135 graus, que têm lobo central e portanto detectam *linha*, cobrindo as quatro orientações pedidas no enunciado; dois Gabor de **fase ímpar** (seno) a 0 e 90 graus, antissimétricos, que detectam *borda* — a distinção importa porque uma parede de tijolos e um ripado de madeira podem ter a mesma orientação dominante e ainda assim serem coisas diferentes; e um **filtro circular**, o Laplaciano da gaussiana, isotrópico, que responde a granulação sem direção preferida e é quem caracteriza asfalto e brita. Todos têm média zero, então nenhum responde a brilho constante.




Figura 1. Os sete filtros de uma escala. Em cima o núcleo 15x15 (vermelho positivo, azul negativo); embaixo o módulo da resposta em frequência, onde cada Gabor aparece como um par de lobos na direção correspondente e o circular como um anel.

Para o multiescala, o enunciado permite construir os filtros em três tamanhos ou construí-los uma vez e encolher a imagem. Adotou-se o segundo, mais barato. A pirâmide gaussiana suaviza com $\sigma = 1,0$ e amostra um pixel a cada dois, dando níveis de 512x512, 256x256 e 128x128; como o filtro continua 15x15, no nível 2 ele enxerga uma vizinhança quatro vezes maior da imagem original. Sete filtros em três escalas produzem 21 mapas de resposta. De cada mapa toma-se o valor absoluto, porque uma barra clara sobre fundo escuro e uma barra escura sobre fundo claro são a mesma textura, e sem retificar a média da janela daria aproximadamente zero para as duas.

4. O descritor de 24 dimensões

O descritor de uma região é a média de cada mapa de resposta dentro da janela, o que dá 21 números. Usá-los crus não funciona bem: eles carregam o contraste da foto, e a distância euclidiana passa a medir *quanto contraste a imagem tem* em vez de *que textura ela é* — a mesma parede ao sol e na sombra vira dois grupos.

A correção é separar as duas coisas. Cada escala passa a ser descrita por oito números: as sete frações $r_i/(r_1 + \dots + r_7)$, que dizem como a energia se reparte entre as orientações e o filtro circular — a *forma* da assinatura, invariante a contraste — e o valor $\log(1 + r_1 + \dots + r_7)$, a energia total daquela escala, isto é, o *tamanho*. Três escalas por oito números dão as 24 dimensões. A Tabela 1 mostra o ganho medido, mudando apenas a forma do descritor.

Tabela 1. Efeito da forma do descritor sobre a pureza do agrupamento.

Descritor	Dimensões	Pureza (k=8)
médias cruas dos filtros e passa-baixa	24	0,40
médias cruas, sem a passa-baixa	21	0,45
logaritmo das médias cruas	24	0,50
perfil normalizado e energia por escala	24	0,58

O mesmo cálculo serve em duas granularidades. Com a imagem inteira como janela, sai um vetor por imagem, usado para agrupar o conjunto. Com janelas de 64x64 px andando de 32 em 32 px, saem 225 vetores por imagem, usados para segmentar por dentro; a janela é maior que o passo de propósito, porque com janelas justas de 32x32 o mapa de rótulos fica pipocado.

5. Agrupamento e resultados

O agrupamento é um k-médias euclidiano implementado à mão, com inicialização k-means++ [Arthur and Vassilvitskii 2007], semente fixa e dez reinicializações, ficando com a de menor inércia. Antes, cada dimensão passa por z-score: as frações vivem entre 0 e 1 e a energia logarítmica vale alguns inteiros, então sem normalizar a distância seria dominada pelas dimensões de energia.

Nem a inércia nem a silhueta indicam um k natural — as texturas urbanas formam um contínuo, não oito nuvens separadas. Adotou-se $k = 8$, o número de materiais fotografados, que dá pureza 0,575 e silhueta 0,220. A pureza é a fração de imagens que está no rótulo majoritário do seu grupo, e é preciso lembrar que ela pune o método quando ele está certo mas discorda da etiqueta: um concreto muito granulado realmente se parece mais com brita do que com um concreto liso.

A pureza de 0,575 esconde um comportamento que a Figura 2 torna evidente: os grupos são coerentes como textura, ainda quando não coincidem com o material. G6 junta as cinco britas com concretos granulados e paralelepípedos rugosos — todos são granulação grossa isotrópica, e o filtro circular os vê como a mesma coisa. G4 junta tijolo, calçada em blocos e telha em fiadas, que são todos retângulos separados por juntas horizontais. Os erros que restam são de dois tipos: a classe que se parte, como as telhas, espalhadas por três grupos porque telha de frente, em diagonal e empilhada são texturas

Tabela 2. Composição dos oito grupos encontrados.

Grupo	n	O que reuniu
G0	7	superfícies granuladas de contraste médio
G1	1	tapume claro de ripas verticais
G2	3	veio de madeira horizontal
G3	2	telhas em fiadas diagonais
G4	9	alvenaria: blocos com juntas horizontais fortes
G5	5	superfícies lisas de granulação fina
G6	9	granulado grosso e sem direção
G7	4	placas grandes e lisas separadas por juntas largas

diferentes com o mesmo nome; e os grupos de um elemento só, de imagens atípicas demais para se juntar a qualquer outra.

Rodando o mesmo k -médias sobre as 9.000 janelas de 64×64 de todas as imagens, com $k = 6$, cada janela recebe o rótulo do grupo mais próximo, o que produz um mapa de segmentação por textura (Figura 3). Este é o resultado mais fácil de auditar a olho: as regiões que o método separa — as frestas entre ripas de madeira, o rejunte entre as pedras, a junta entre placas de concreto — são as que uma pessoa apontaria. O mapa é grosseiro por construção, com limites em degraus de 32 px.

Para verificar quanto o resultado depende do banco escolhido, todo o *pipeline* foi repetido com derivadas de gaussiana [Freeman and Adelson 1991] — 2ª derivada no lugar do Gabor par, 1ª derivada no lugar do ímpar, mesmo filtro circular — mantendo idênticos o conjunto, a pirâmide, o descritor e o agrupamento. A troca quase não muda nada: mesma pureza, índice de Rand [Rand 1971] de 0,98 entre os dois agrupamentos e uma única imagem das 40 trocando de grupo. O descritor descarta a diferença, porque a média do módulo numa janela de 64×64 , depois normalizada pela energia, dá quase o mesmo número vindo de filtros diferentes.

6. Limitações e conclusão

O método não tem invariância a rotação — girar a foto 45 graus muda o descritor por completo, consequência de usar orientações fixas — nem a escala de aquisição, já que as três escalas cobrem uma faixa de apenas 4x. O k foi escolhido à mão, por corresponder ao número de materiais, que é informação externa ao método. E o conjunto é pequeno: 40 imagens vindas de 36 fotos.

Ainda assim, um banco de sete filtros orientados aplicado em três escalas e resumido pela média das respostas em cada janela é suficiente para agrupar texturas urbanas de maneira visualmente coerente e para segmentar o interior das imagens sem nenhum aprendizado. O passo que mais afetou o resultado não foi a escolha dos filtros, e sim a forma do descritor: separar a repartição da energia entre os filtros da quantidade total de energia levou a pureza de 0,40 para 0,58. Trocar o banco inteiro, em contraste, deixou o resultado essencialmente intacto.

As 40 imagens organizadas pelos 8 grupos do k-medias (cor da moldura = grupo)




Figura 2. As 40 imagens organizadas pelos oito grupos do k-médias. A cor da moldura indica o grupo.




Figura 3. Segmentação por textura: acima as imagens originais, abaixo o mapa de grupos sobreposto. Uma imagem de textura uniforme fica quase toda de uma cor só; onde há mais de um material, o limite aparece.

Referências

- Arthur, D. and Vassilvitskii, S. (2007). k-means++: the advantages of careful seeding. In *Proceedings of the 18th Annual ACM-SIAM Symposium on Discrete Algorithms (SODA)*, pages 1027–1035.
- Freeman, W. T. and Adelson, E. H. (1991). The design and use of steerable filters. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 13(9):891–906.
- Gabor, D. (1946). Theory of communication. *Journal of the Institution of Electrical Engineers*, 93(26):429–457.
- Jain, A. K. and Farrokhnia, F. (1991). Unsupervised texture segmentation using Gabor filters. *Pattern Recognition*, 24(12):1167–1186.
- Rand, W. M. (1971). Objective criteria for the evaluation of clustering methods. *Journal of the American Statistical Association*, 66(336):846–850.
- Randen, T. and Husøy, J. H. (1999). Filtering for texture classification: a comparative study. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 21(4):291–310.