

Segmentação de texturas urbanas com um banco de filtros orientados em três escalas

Vitor Lorenzo Cumim¹

¹Universidade Federal do Paraná (UFPR) – Visão Computacional, Trabalho 1

vlc22@inf.ufpr.br

Abstract. *This work builds a 24-dimensional texture descriptor from a bank of seven filters — four even-phase Gabor filters oriented at 0, 45, 90 and 135 degrees, two odd-phase Gabor filters and one circular Laplacian of Gaussian — applied over three levels of a Gaussian pyramid. Each region is described by the mean filter response inside a window, rearranged as an energy profile plus a total energy per scale. A hand-written Euclidean k-means groups 40 grayscale crops of 512x512 pixels from eight urban materials, reaching a purity of 0.58 against the photographed material. The same descriptor, computed on 64x64 windows, segments the interior of each image and tells mortar joints from brick faces.*

Resumo. *Este trabalho monta um descritor de textura de 24 dimensões a partir de um banco de sete filtros — quatro Gabor de fase par nas orientações 0, 45, 90 e 135 graus, dois Gabor de fase ímpar e um filtro circular (Laplaciano da gaussiana) — aplicados em três escalas de uma pirâmide gaussiana. Cada região é descrita pela média das respostas dentro de uma janela, reorganizada em perfil de energia e energia total por escala. Um k-médias euclidiano escrito à mão agrupa 40 recortes de 512x512 pixels em tons de cinza, de oito materiais urbanos, com pureza de 0,58 em relação ao material fotografado. O mesmo descritor, calculado em janelas de 64x64, segmenta o interior das imagens e separa as juntas de argamassa das faces dos tijolos.*

1. Introdução

Duas regiões de uma imagem em tons de cinza podem ter exatamente o mesmo histograma e ainda assim serem visivelmente diferentes. Uma parede de tijolos e um trecho de asfalto podem ter o mesmo brilho médio, mas a parede tem linhas horizontais fortes e o asfalto não tem direção nenhuma. É essa diferença — como a intensidade varia no espaço, em que direção e em que tamanho — que chamamos de textura.

A estratégia clássica para medi-la é passar a imagem por um conjunto de filtros sintonizados em diferentes orientações e frequências e observar quanta energia cada um capta [Jain and Farrokhnia 1991, Randen and Husøy 1999]. Este trabalho segue essa receita, com filtros de Gabor [Gabor 1946] e um filtro circular, e usa os vetores resultantes para duas tarefas: agrupar um conjunto de 40 imagens por semelhança de textura e segmentar o interior de cada imagem.

Nenhuma etapa usa aprendizado de máquina: os filtros são fixos e projetados analiticamente, e o agrupamento é um k-médias euclidiano implementado diretamente. O código e as imagens estão em <https://github.com/vitorcumim/textura-urbana>.

2. Conjunto de imagens

O conjunto é de texturas urbanas: asfalto, brita, calçada, concreto, madeira, paralelepípedo, telha e tijolo — oito classes, cinco imagens cada, 40 imagens no total.

As fotos vieram do Wikimedia Commons, sob licenças livres (CC0, CC BY, CC BY-SA e domínio público). O arquivo `creditos.csv` do repositório registra título, autor, licença e endereço de origem de cada foto; ele é gerado por um script que confere o SHA-256 do arquivo local contra a imagem publicada, de modo que o crédito nunca seja atribuído à foto errada. Cabe a ressalva de que o enunciado pede fotos tiradas pelo próprio grupo, e estas não são; o código foi escrito de modo que a troca custe um comando.

A busca textual do acervo é pouco confiável para este fim. Pedir *chain link fence* devolve retratos de pessoas com uma cerca desfocada ao fundo, e *asphalt texture* devolve cartas de ruído usadas para calibrar *scanners*. Foram baixadas 89 fotos candidatas, todas submetidas a curadoria visual em folhas de contato; sobraram 36. Uma nona classe pretendida, grades metálicas, foi abandonada porque nenhuma das 16 candidatas era utilizável.

Cada foto aprovada é convertida para tons de cinza pela fórmula da ITU-R BT.601, $Y = 0,299R + 0,587G + 0,114B$, e recortada em blocos de 512x512 tomados de uma grade centrada, sem sobreposição, de modo que dois recortes da mesma foto nunca compartilhem pixels.

3. O banco de filtros

3.1. Os sete filtros

Um filtro de Gabor é uma onda cosseno (ou seno) multiplicada por uma envoltória gaussiana. Ele responde forte onde a imagem tem variação periódica com a orientação e o comprimento de onda para os quais foi sintonizado. Os parâmetros usados são $\lambda = 5$ px de comprimento de onda, $\sigma = 2,2$ px de envoltória, razão de aspecto $\gamma = 0,5$ e núcleo de 15x15 px.

O banco tem sete filtros:

- **quatro Gabor de fase par** (cosseno), nas orientações 0, 45, 90 e 135 graus. A fase par tem um lobo central: é um detector de *linha*. São eles que cobrem as quatro orientações pedidas no enunciado;
- **dois Gabor de fase ímpar** (seno), em 0 e 90 graus. A fase ímpar é antissimétrica: é um detector de *borda*, de degrau de intensidade. A distinção importa porque uma parede de tijolos e um ripado de madeira podem ter a mesma orientação dominante e ainda assim serem coisas diferentes — um tem degraus, o outro tem linhas;
- **um filtro circular**, o Laplaciano da gaussiana ($\sigma = 2,0$). É isotrópico: sua resposta em frequência é um anel, não um par de lobos. Responde a granulação e manchas sem direção preferida, e é ele que caracteriza asfalto e brita.

Todos os sete têm média zero, isto é, DC nulo, o que garante que nenhum responda a brilho constante: uma parede clara e a mesma parede na sombra dão a mesma resposta, a menos do contraste.

A convenção de orientação adotada é a da estrutura detectada: um filtro a 0 graus responde a listras horizontais. Como a onda precisa variar na direção perpendicular às listras, o código usa $\theta = \alpha + 90^\circ$ na fórmula da gaussiana modulada.




Figura 1. Os sete filtros de uma escala. Em cima o núcleo 15x15 (vermelho positivo, azul negativo); embaixo o módulo da resposta em frequência, onde cada Gabor aparece como um par de lobos na direção correspondente e o circular como um anel.

3.2. As três escalas

O enunciado oferece dois caminhos para o multiescala: construir os filtros em três tamanhos, ou construí-los uma vez só e encolher a imagem. Adotou-se o segundo, mais barato — convoluir com um núcleo 15x15 numa imagem que encolhe custa bem menos que convoluir com núcleos 15x15, 29x29 e 57x57 na imagem cheia.

A pirâmide é a gaussiana clássica: suaviza com uma gaussiana ($\sigma = 1,0$) e amostra um pixel a cada dois em cada dimensão, dando níveis de 512x512, 256x256 e 128x128. Como o filtro não muda de tamanho, no nível 2 ele enxerga uma vizinhança quatro vezes maior da imagem original, o que dá a sensibilidade a texturas grossas.

Sete filtros em três escalas produzem 21 mapas de resposta por imagem. De cada mapa toma-se o valor absoluto: uma barra clara sobre fundo escuro e uma barra escura sobre fundo claro são a mesma textura, e sem retificar a média da janela daria aproximadamente zero para as duas. Os mapas dos níveis menores são reamostrados de volta para 512x512, para que todos fiquem na mesma grade.

4. O descritor de 24 dimensões

O descritor de uma região é, como pede o enunciado, a média de cada mapa de resposta dentro da janela, o que dá 21 números. A conversão desses 21 números nas 24 dimensões finais é a única decisão de projeto não óbvia deste trabalho.

O problema das médias cruas é que elas carregam o contraste da foto. A mesma parede fotografada ao sol e na sombra produz vetores de comprimentos bem diferentes, apontando praticamente na mesma direção. Uma distância euclidiana calculada sobre esses vetores mede sobretudo *quanto contraste a foto tem*, e não *que textura ela é*. Na prática isso aparecia como grupos formados por fotos claras e fotos escuras, misturando materiais.




Figura 2. Módulo da resposta dos sete filtros nas três escalas, para um recorte de parede de tijolos. As juntas horizontais de argamassa acendem no filtro “par 0” e quase somem no “par 90”; o filtro circular responde à granulação da própria superfície do tijolo.

A correção é separar as duas coisas. Cada escala passa a ser descrita por oito números: as sete frações $r_i/(r_1 + \dots + r_7)$, que dizem como a energia se reparte entre as orientações e o filtro circular — a *forma* da assinatura, invariante a contraste — e o valor $\log(1 + r_1 + \dots + r_7)$, a energia total daquela escala, isto é, o *tamanho*. O logaritmo comprime a cauda longa, para que uma única junta de argamassa muito contrastada não domine o vetor. Três escalas por oito números dão as 24 dimensões.

A Tabela 1 mostra o ganho medido, com o mesmo *pipeline* e mudando apenas a forma do descritor.

Tabela 1. Efeito da forma do descritor sobre a pureza do agrupamento.

Descritor	Dimensões	Pureza (k=8)
médias cruas dos filtros e passa-baixa	24	0,40
médias cruas, sem a passa-baixa	21	0,45
logaritmo das médias cruas	24	0,50
perfil normalizado e energia por escala	24	0,58

Duas granularidades são calculadas com a mesma função. No **descritor global**, a janela é a imagem inteira, e sai um vetor de 24 dimensões por imagem, usado para agrupar o conjunto. No **descritor local**, janelas de 64x64 px andam de 32 em 32 px, com 50% de sobreposição, o que dá uma grade de 15x15 janelas por imagem, 9.000 no conjunto todo. A janela é maior que o passo de propósito: com janelas justas de 32x32 o mapa de rótulos fica pipocado, porque uma janela desse tamanho às vezes cai inteira dentro de uma junta de argamassa e não vê textura nenhuma, só o vazio.

5. Agrupamento

O agrupamento é um k-médias euclidiano implementado à mão. Três detalhes importam. O primeiro é a **normalização z-score por dimensão**, obrigatória aqui: as frações vivem

entre 0 e 1 e a energia logarítmica vale alguns inteiros, de modo que sem normalizar a distância euclidiana seria dominada pelas dimensões de energia e as de orientação seriam ignoradas. O segundo é a **inicialização k-means++** [Arthur and Vassilvitskii 2007], que sorteia centroides iniciais afastados entre si; com semente fixa, a execução é determinística. O terceiro são as **dez reinicializações**, ficando com a de menor inércia, já que o k-médias converge para mínimos locais.

Para avaliar, usam-se três medidas: a inércia (soma das distâncias ao quadrado ao centroide), a silhueta média e a pureza em relação ao material fotografado — a fração de imagens que está no rótulo majoritário do seu grupo. A pureza é a única que usa a resposta certa, e é preciso lembrar que ela pune o método quando ele está certo mas discorda da etiqueta: um concreto muito granulado realmente se parece mais com brita do que com um concreto liso.

6. Resultados

6.1. Escolha de k




Figura 3. Inércia (esquerda), silhueta e pureza (direita) em função de k, para o agrupamento das 40 imagens.

A curva de inércia não tem um cotovelo marcado, o que já diz algo sobre o conjunto: as texturas urbanas formam um contínuo, não oito nuvens bem separadas. A silhueta fica entre 0,21 e 0,28 para todo k de 2 a 14, sem pico claro. A pureza cresce de forma quase monótona, como esperado — com $k = 40$ ela seria 1,0 e não significaria nada. Adotou-se $k = 8$, o número de materiais fotografados, que dá pureza 0,575 e silhueta 0,220, e que permite comparar diretamente os grupos encontrados com as classes reais.

6.2. Agrupamento das 40 imagens

A pureza de 0,575 esconde um comportamento que a Figura 4 torna evidente: os grupos são coerentes como textura, ainda quando não coincidem com o material. G6 junta as cinco britas com dois concretos granulados e dois paralelepípedos rugosos — todos são granulação grossa isotrópica, e o filtro circular os vê como a mesma coisa. G4 junta tijolo, calçada em blocos e telha em fiadas: todos são retângulos separados por juntas horizontais. G5 junta asfalto novo com concreto liso, que de fato são indistinguíveis em cinza naquela escala.

Tabela 2. Composição dos oito grupos encontrados.

Grupo	n	O que reuniu
G0	7	superfícies granuladas de contraste médio: asfalto, pedra desgastada
G1	1	tapume claro de ripas verticais
G2	3	veio de madeira horizontal, listras finas e alongadas
G3	2	telhas em fiadas diagonais
G4	9	alvenaria: blocos com juntas horizontais fortes
G5	5	superfícies lisas de granulação fina: asfalto novo, concreto liso
G6	9	granulado grosso e sem direção: brita, concreto granulado, pedra
G7	4	placas grandes e lisas separadas por juntas largas

Os erros que restam são de dois tipos. O primeiro é a classe que se parte: as cinco telhas ficaram espalhadas por três grupos, porque telha vista de frente, em diagonal e em fiada empilhada são três texturas diferentes que por acaso têm o mesmo nome. O segundo são os grupos de um elemento só, que aparecem quando uma imagem é atípica demais para se juntar a qualquer outra.

6.3. Segmentação dentro das imagens

Rodando o mesmo k-médias sobre as 9.000 janelas de 64x64 de todas as imagens, com $k = 6$, cada janela recebe o rótulo do grupo mais próximo. Pintando cada janela com a cor do seu grupo obtém-se um mapa de segmentação por textura.

Este é o resultado mais fácil de auditar a olho: as regiões que o método separa são exatamente as que uma pessoa apontaria. O mapa é grosseiro por construção — a menor unidade é uma janela de 64x64, então os limites saem em degraus de 32 px.

6.4. Trocando o banco de filtros

Para verificar quanto do resultado depende do banco escolhido, todo o *pipeline* foi repetido com um banco de derivadas de gaussiana [Freeman and Adelson 1991], mantendo idênticos o conjunto, a pirâmide, o descritor e o agrupamento. O paralelo é filtro a filtro: a 2ª derivada da gaussiana ocupa o lugar do Gabor de fase par (detector de linha), a 1ª derivada ocupa o lugar do Gabor de fase ímpar (detector de borda), e o filtro circular é o mesmo.

O resultado é que a troca quase não muda nada. Os dois bancos dão a mesma pureza, e os agrupamentos são praticamente o mesmo objeto: o índice de Rand [Rand 1971] entre eles é 0,98, e uma única imagem das 40 troca de grupo — um trecho de placa de concreto com pouca textura e uma junta atravessando, que é um caso de fronteira.

A diferença entre os filtros existe e é mensurável. Em largura absoluta as duas bandas são quase iguais, 0,16 ciclos por pixel a meia altura, mas o Gabor tem o pico em

As 40 imagens organizadas pelos 8 grupos do k-medias (cor da moldura = grupo)




Figura 4. As 40 imagens organizadas pelos oito grupos do k-médias. A cor da moldura indica o grupo.




Figura 5. Matriz de confusão entre a classe da foto e o grupo encontrado.

0,20 ciclos/px e a derivada em 0,14, o que torna a derivada proporcionalmente mais larga: 1,8 oitavas contra 1,2. O Gabor é mais seletivo, porém por uma margem modesta nesta configuração.

Três razões explicam por que isso não chega ao resultado. A primeira é que o descritor descarta boa parte da diferença: o que entra no vetor é a média do módulo da resposta numa janela de 64x64, depois normalizada pela energia total da escala, e duas medidas de “quanta energia horizontal existe nesta janela” tendem a concordar mesmo vindo de filtros diferentes. A segunda é que a pirâmide cobre a mesma faixa de tamanhos nos dois casos. A terceira é que metade do conjunto — asfalto, brita, concreto — não tem frequência definida nenhuma para a seletividade do Gabor premiar.

7. Limitações

- **Sem invariância a rotação.** Girar a foto 45 graus muda o descritor por completo, consequência direta de usar orientações fixas. A correção usual é tomar o máximo das respostas sobre as orientações, como no banco MR8 [Varma and Zisserman 2005], ao custo de perder justamente a informação de direção que separa madeira de tijolo aqui.
- **Sem invariância a escala de aquisição.** As três escalas cobrem uma faixa de 4x em tamanho de elemento; uma parede fotografada de perto e de longe pode cair em grupos diferentes.
- **k escolhido à mão.** Nem a inércia nem a silhueta indicam um k natural; adotou-se $k = 8$ por corresponder ao número de materiais, que é informação externa ao




Figura 6. Segmentação por textura: acima as imagens originais, abaixo o mapa de grupos sobreposto. Uma imagem de textura uniforme fica quase toda de uma cor só; onde há mais de um material, o limite aparece.

método.

- **Conjunto pequeno.** São 40 imagens vindas de 36 fotos, e algumas classes tiveram poucas fotos boas disponíveis, o que obrigou a tirar dois recortes da mesma foto.

8. Conclusão

Um banco de sete filtros orientados, aplicado em três escalas e resumido pela média das respostas em cada janela, é suficiente para agrupar texturas urbanas de maneira visualmente coerente e para segmentar o interior das imagens sem nenhum aprendizado. A pureza de 0,58 contra o material fotografado subestima o método: a inspeção das figuras mostra que os grupos separam *aparências de textura*, e materiais diferentes com a mesma aparência caem juntos, o que é o comportamento correto para um descritor que só enxerga variação de intensidade.

O passo que mais afetou o resultado não foi a escolha dos filtros, e sim a forma do descritor: separar a repartição da energia entre os filtros da quantidade total de energia levou a pureza de 0,40 para 0,58. Trocar o banco inteiro de Gabor por derivadas de gaussiana, em contraste, deixou o resultado essencialmente intacto.

Detalhe: nas imagens com mais de uma textura o limite aparece sozinho no mapa de grupos




Figura 7. Detalhe em quatro imagens. As frestas entre as ripas de madeira, o rejunte entre as pedras e a junta entre as placas de concreto saem separados das superfícies vizinhas.

Os dois bancos lado a lado - pureza 0.53 (Gabor) contra 0.53 (gaussiana), Rand 0.98




Figura 8. Os dois bancos lado a lado. Em cima os Gabor, no meio as derivadas de gaussiana, embaixo o corte do espectro do filtro de linha a 0 graus de cada banco, com o pico e a largura a meia altura marcados.

Referências

- Arthur, D. and Vassilvitskii, S. (2007). k-means++: the advantages of careful seeding. In *Proceedings of the 18th Annual ACM-SIAM Symposium on Discrete Algorithms (SODA)*, pages 1027–1035.
- Freeman, W. T. and Adelson, E. H. (1991). The design and use of steerable filters. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 13(9):891–906.
- Gabor, D. (1946). Theory of communication. *Journal of the Institution of Electrical Engineers*, 93(26):429–457.
- Jain, A. K. and Farrokhnia, F. (1991). Unsupervised texture segmentation using Gabor filters. *Pattern Recognition*, 24(12):1167–1186.
- Rand, W. M. (1971). Objective criteria for the evaluation of clustering methods. *Journal of the American Statistical Association*, 66(336):846–850.
- Randen, T. and Husøy, J. H. (1999). Filtering for texture classification: a comparative study. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 21(4):291–310.
- Varma, M. and Zisserman, A. (2005). A statistical approach to texture classification from single images. *International Journal of Computer Vision*, 62(1–2):61–81.