

Segmentação de texturas urbanas com um banco de filtros orientados em três escalas

Vitor Lorenzo Cumim

Visão Computacional — Trabalho 1 · setembro de 2026

codigo: <https://github.com/vitorcumim/textura-urbana>

Resumo

Este trabalho monta um descritor de textura de 24 dimensões a partir de um banco de sete filtros — quatro Gabor de fase par nas orientações 0°, 45°, 90° e 135°, dois Gabor de fase ímpar em 0° e 90° e um filtro circular (Laplaciano da gaussiana) — aplicados em três escalas de uma pirâmide gaussiana. O descritor de cada região é a média das respostas dentro de uma janela, reorganizada em *perfil* (como a energia se reparte entre os filtros) e *energia total* por escala. Um k-médias euclidiano escrito à mão agrupa 40 recortes de 512×512 pixels em tons de cinza, de oito materiais urbanos. Com $k = 8$ os grupos encontrados têm pureza de 0,58 em relação ao material fotografado, e a inspeção visual mostra que os erros não são aleatórios: o método agrupa por *aparência de textura*, e materiais diferentes com a mesma aparência caem juntos. O mesmo descritor, calculado em janelas de 64×64 pixels, segmenta o interior das imagens e separa, por exemplo, as juntas de argamassa das faces dos tijolos.

1. Introdução

Duas regiões de uma imagem em tons de cinza podem ter exatamente o mesmo histograma e ainda assim serem visivelmente diferentes: uma parede de tijolos e um trecho de asfalto podem ter o mesmo brilho médio, mas a parede tem linhas horizontais fortes e o asfalto não tem direção nenhuma. É essa diferença — como a intensidade *varia* no espaço, e em que direção e em que tamanho — que chamamos de textura.

A estratégia clássica para medi-la é passar a imagem por um conjunto de filtros sintonizados em diferentes orientações e frequências e olhar quanta energia cada um capta. Este trabalho segue exatamente essa receita, com filtros de Gabor e um filtro circular, e usa os vetores resultantes para duas tarefas: agrupar um conjunto de 40 imagens por semelhança de textura e segmentar o interior de cada imagem.

Nada aqui usa aprendizado de máquina moderno: os filtros são fixos e projetados analiticamente, e o agrupamento é um k-médias euclidiano de trinta linhas.

2. Conjunto de imagens

2.1 Origem

O conjunto é de **texturas urbanas**: asfalto, brita, calçada, concreto, madeira (tapumes e ripados), paralelepípedo, telha e tijolo — oito classes, cinco imagens cada, **40 imagens** no total.

As fotos vieram do Wikimedia Commons, sob licenças livres (CC0, CC BY, CC BY-SA e domínio público). O arquivo `fotos_originais/creditos.csv` registra, para cada foto usada, o título, o autor, a licença e o endereço da página de origem; esse arquivo é gerado por `src/creditos.py`, que confere o SHA-256 do arquivo local contra a imagem publicada no Commons, de modo que o crédito nunca é atribuído à foto errada.

Vale registrar uma ressalva honesta: o enunciado pede fotos tiradas pelo próprio grupo, e estas não são. O código foi escrito de modo que essa troca custe um comando — basta colocar as fotos próprias em `fotos_originais/<classe>/`, apagar o arquivo `selecao.txt` e rodar o pipeline de novo; nada mais muda.

A busca textual do Commons é ruim para este fim. Pedir "chain link fence" devolve retratos de pessoas com uma cerca desfocada ao fundo, e "asphalt texture" devolve cartas de ruído usadas para calibrar scanners. Por isso foram baixadas 89 fotos candidatas e todas passaram por curadoria visual em folhas de contato; sobraram 36 fotos, listadas em `selecao.txt`. Uma nona classe pretendida, grades metálicas, foi abandonada porque nenhuma das 16 candidatas era utilizável.

2.2 Preparo

Cada foto aprovada é convertida de RGB para tons de cinza pela fórmula da ITU-R BT.601, que é implementada por `cv2.cvtColor(..., COLOR_BGR2GRAY)`:

$$Y = 0,299 R + 0,587 G + 0,114 B$$

Em seguida a foto é recortada em blocos de **512×512** tomados de uma grade centrada, sem sobreposição, de modo que dois recortes da mesma foto nunca compartilham pixels. Das fotos com textura mais escassa (asfalto e brita) foram tirados dois recortes; das demais, um. O resultado são as 40 imagens de `imagens/`.

As 40 imagens organizadas pelos 8 grupos do k-medias (cor da moldura = grupo)




Figura 1. As 40 imagens do conjunto, já em tons de cinza e recortadas em 512×512, organizadas pelos grupos que o método encontrou (Seção 6).

3. O banco de filtros

3.1 Os sete filtros

Um filtro de Gabor é uma onda cosseno (ou seno) multiplicada por uma envoltória gaussiana. Ele responde forte onde a imagem tem uma variação periódica com a orientação e o comprimento de onda para os quais foi sintonizado, e responde fraco em qualquer outro lugar. Os parâmetros usados são $\lambda = 5$ px de comprimento de onda, $\sigma = 2,2$ px de envoltória, razão de aspecto $\gamma = 0,5$ e núcleo de 15×15 px.

O banco tem sete filtros:

- **quatro Gabor de fase par** (cosseno), nas orientações 0° , 45° , 90° e 135° . A fase par tem um lobo central: é um detector de **linha**. São eles que cobrem as quatro orientações pedidas no enunciado — horizontal, 45° , vertical e 135° ;
- **dois Gabor de fase ímpar** (seno), em 0° e 90° . A fase ímpar é antissimétrica: é um detector de **borda**, de degrau de intensidade. A distinção importa porque uma parede de tijolos e um ripado de madeira podem ter a mesma orientação dominante e mesmo assim serem coisas diferentes — um tem degraus, o outro tem linhas;
- **um filtro circular**, o Laplaciano da gaussiana ($\sigma = 2,0$). Ele é isotrópico: sua resposta em frequência é um anel, não um par de lobos. Responde a granulação e manchas sem direção preferida, e é ele que caracteriza asfalto e brita, que não têm orientação dominante nenhuma.

Todos os sete têm média zero, isto é, DC nulo. Isso garante que nenhum deles responda a brilho constante: uma parede clara e a mesma parede na sombra dão a mesma resposta, a menos do contraste.

A convenção de orientação adotada é a da *estrutura detectada*: um filtro a 0° responde a listras horizontais. Internamente a onda precisa variar na direção perpendicular às listras, então o código usa $\theta = \alpha + 90^\circ$ na fórmula da gaussiana modulada.




Figura 2. Os sete filtros de uma escala. Em cima o núcleo 15×15 (vermelho positivo, azul negativo); embaixo o módulo da resposta em frequência, onde se vê que cada Gabor é um par de lobos na direção correspondente e o circular é um anel.

3.2 As três escalas

O enunciado oferece dois caminhos para o multiescala: construir os filtros em três tamanhos, ou construir os filtros uma vez só e encolher a imagem. Adotamos o segundo, que é mais barato — convoluir com um núcleo 15×15 três vezes numa imagem que encolhe custa muito menos que convoluir com núcleos 15×15 , 29×29 e 57×57 na imagem cheia.

A pirâmide é a gaussiana clássica: suaviza com uma gaussiana ($\sigma = 1,0$) e amostra um pixel a cada dois em cada dimensão. Os três níveis são 512×512 , 256×256 e 128×128 . Como o filtro não muda de tamanho, no nível 2 ele enxerga uma vizinhança quatro vezes maior da imagem original — é isso que dá a sensibilidade a texturas grossas.

Pirâmide gaussiana: o filtro não muda de tamanho, a imagem é que encolhe pela metade




Figura 3. A pirâmide gaussiana: o filtro tem sempre 15×15 px, a imagem é que encolhe pela metade a cada nível.

Sete filtros vezes três escalas dão **21 mapas de resposta** por imagem. De cada mapa toma-se o **valor absoluto**: uma barra clara sobre fundo escuro e uma barra escura sobre fundo claro são a mesma textura, e sem retificar a média da janela daria aproximadamente zero para as duas. Os 21 mapas dos níveis menores são reamostrados de volta para 512×512 para que todos fiquem na mesma grade.




Figura 4. Módulo da resposta dos sete filtros nas três escalas para um recorte de parede de tijolos. As juntas horizontais de argamassa acendem no filtro "par 0" e quase somem no "par 90"; o filtro circular responde à granulação da própria superfície do tijolo.

4. O descritor de 24 dimensões

O descritor de uma região é, como pede o enunciado, a **média de cada mapa de resposta dentro da janela**. Isso dá 21 números por janela. A conversão desses 21 números nas 24 dimensões finais é onde está a única decisão de projeto não óbvia deste trabalho, e vale explicá-la.

O problema das médias cruas é que elas carregam o contraste da foto. A mesma parede fotografada ao sol e na sombra produz vetores de comprimentos bem diferentes, apontando praticamente na mesma direção. Uma distância euclidiana calculada sobre esses vetores mede sobretudo *quanto contraste a foto tem*, e não *que textura ela é*. Na prática isso aparecia como grupos formados por "fotos claras" e "fotos escuras", misturando materiais.

A correção é separar as duas coisas. Cada escala passa a ser descrita por oito números:

- as **sete frações** $r_i / (r_1 + \dots + r_7)$, que dizem como a energia se reparte entre as orientações e o filtro circular. É a *forma* da assinatura, e ela é invariante a contraste: é o que responde "esta textura é horizontal, diagonal, ou sem direção?";

- **um valor** $\log(1 + r_1 + \dots + r_7)$, a energia total daquela escala. É o *tamanho*: quanta textura existe ali. O logaritmo comprime a cauda longa, para que uma única junta de argamassa muito contrastada não domine o vetor inteiro.

Três escalas $\times$ oito números = **24 dimensões**. A tabela abaixo mostra o ganho medido: a mesma pipeline, mudando apenas a forma do descritor.

Descritor	dimensões	pureza (k=8)
médias cruas dos filtros + passa-baixa	24	0,40
médias cruas, sem a passa-baixa	21	0,45
logaritmo das médias cruas	24	0,50
perfil normalizado + energia por escala	24	0,58

Duas granularidades são calculadas com a mesma função:

- **descritor global**: a janela é a imagem inteira. Sai um vetor de 24 dimensões por imagem, 40 no total, usado para agrupar o conjunto;
- **descritor local**: janelas de **64×64 px andando de 32 em 32 px** (50% de sobreposição), o que dá uma grade de $15 \times 15 = 225$ janelas por imagem, 9.000 no conjunto todo. Esses são usados para segmentar o interior das imagens. A janela é maior que o passo de propósito: com janelas justas de 32×32 o mapa de rótulos fica pipocado, porque uma janela desse tamanho às vezes cai inteira dentro de uma junta de argamassa e não vê textura nenhuma, só o vazio.

5. Agrupamento

O agrupamento é um **k-médias euclidiano** implementado à mão, com numpy apenas para a álgebra. Três detalhes importam:

- **normalização z-score por dimensão**, obrigatória aqui. As 24 dimensões têm escalas muito diferentes — as frações vivem entre 0 e 1, a energia logarítmica vale alguns inteiros. Sem normalizar, a distância euclidiana seria dominada pelas dimensões de energia e as de orientação seriam ignoradas;
- **inicialização k-means++**, que sorteia centroides iniciais afastados uns dos outros com probabilidade proporcional à distância ao centroide mais próximo já escolhido. Com semente fixa (42), a execução é determinística e reproduzível;
- **dez reinicializações**, ficando com a de menor inércia, porque o k-médias converge para mínimos locais.

Para avaliar, usamos três medidas: a **inércia** (soma das distâncias ao quadrado ao centroide), a **silhueta média** (coesão contra separação, entre -1 e 1) e a **pureza** em relação ao material fotografado — a fração de imagens que estão no rótulo majoritário do seu grupo. A pureza é a única que usa a "resposta certa", e é preciso lembrar que ela pune o método quando ele está *certo* mas discorda da etiqueta: um concreto muito granuloso realmente se parece mais com brita do que com um concreto liso.

6. Resultados

6.1 Escolha de k




Figura 5. Inércia (esquerda) e silhueta e pureza (direita) em função de k , para o agrupamento das 40 imagens.

A curva de inércia não tem um cotovelo marcado — o que já diz algo sobre o conjunto: as texturas urbanas formam um contínuo, não oito nuvens bem separadas. A silhueta fica na faixa de 0,21 a 0,28 para todo k entre 2 e 14, sem pico claro. A pureza cresce de forma quase monótona, como esperado (com $k = 40$ ela seria 1,0 e não significaria nada).

Adotamos $k = 8$, o número de materiais fotografados, que dá pureza 0,575 e silhueta 0,220. É a escolha honesta: ela permite comparar diretamente os grupos encontrados com as classes reais.

6.2 Agrupamento das 40 imagens

Grupo	n	O que reuniu
G0	7	superfícies granuladas de contraste médio: asfalto, pedra desgastada
G1	1	tapume claro de ripas verticais (madeira_04)
G2	3	veio de madeira horizontal, listras finas e alongadas
G3	2	telhas em fiadas diagonais
G4	9	alvenaria: blocos com juntas horizontais fortes (tijolo, calçada, telha em fiada)
G5	5	superfícies lisas de granulação fina: asfalto novo, concreto liso
G6	9	granulado grosso e sem direção: brita, concreto granulado, pedra
G7	4	placas grandes e lisas separadas por juntas largas

A pureza de 0,575 esconde um comportamento que a figura torna evidente: **os grupos são coerentes como textura, ainda quando não coincidem com o material**. G6 junta as cinco britas com dois concretos granulados e dois paralelepípedos rugosos — todos são granulação grossa isotrópica, e o filtro circular os vê como a mesma coisa. G4 junta tijolo, calçada em blocos e telha em fiadas: todos são "retângulos separados por juntas horizontais". G5 junta asfalto novo com concreto liso, que de fato são indistinguíveis em cinza a essa escala.

Os erros que restam são de dois tipos. O primeiro é a **classe que se parte**: as cinco telhas ficaram espalhadas por três grupos, porque telha vista de frente, em diagonal e em fiada empilhada são três texturas diferentes que por acaso têm

o mesmo nome. O segundo são os **grupos de um elemento só** (G1), que aparecem quando uma imagem é atípica demais para se juntar a qualquer outra.




Figura 6. Matriz de confusão entre a classe da foto e o grupo encontrado.




Figura 7. As 40 imagens projetadas em duas dimensões por PCA. A projeção descarta boa parte da variância, então grupos que aqui parecem sobrepostos podem estar separados nas 24 dimensões originais.




Figura 8. Assinatura média de cada grupo nas 24 dimensões, valores normalizados. As linhas tracejadas separam as três escalas. Repare em G2 (madeira), que tem excesso de "par 0" e falta de "par 90" nas três escalas — é a definição de textura horizontal.

6.3 Segmentação dentro das imagens

Rodando o mesmo k-médias sobre as 9.000 janelas de 64×64 de todas as imagens, com $k = 6$, cada janela recebe o rótulo do grupo mais próximo. Pintando cada janela com a cor do seu grupo obtém-se um mapa de segmentação por textura.




Figura 9. Segmentação por textura: acima as imagens originais, abaixo o mapa de grupos sobreposto. Uma imagem de textura uniforme fica quase toda de uma cor só; onde há mais de um material, o limite aparece.

Detalhe: nas imagens com mais de uma textura o limite aparece sozinho no mapa de grupos




Figura 10. Detalhe em quatro imagens. Em madeira_00 as duas frestas verticais entre as ripas saem em verde, separadas das faces das ripas; em paralelepipedo_00 as juntas de rejunte saem em laranja e as faces das pedras em roxo; em calçada_02 a junta entre as placas e a faixa de terra na borda esquerda se destacam do concreto.

Este é o resultado mais convincente do trabalho, e é fácil de auditar a olho: as regiões que o método separa são exatamente as que uma pessoa apontaria. Note que o mapa é grosseiro por construção — a menor unidade é uma janela de 64×64, então os limites saem em degraus de 32 px.

7. Limitações

- **Sem invariância a rotação.** Girar a foto 45° muda o descritor por completo. É uma consequência direta de usar orientações fixas. A correção usual é tomar o máximo das respostas sobre as orientações (como no banco MR8), ao custo de perder justamente a informação de direção que separa madeira de tijolo aqui.

- **Sem invariância a escala de aquisição.** As três escalas cobrem uma faixa de $4\times$ em tamanho de elemento. Uma parede de tijolos fotografada de perto e de longe pode cair em grupos diferentes.
- **k escolhido à mão.** Nem a inércia nem a silhueta indicam um k natural; adotamos $k = 8$ por corresponder ao número de materiais, o que é uma informação externa que o método não tem.
- **Conjunto pequeno e desbalanceado em qualidade.** São 40 imagens vindas de 36 fotos, e algumas classes (asfalto, brita) tiveram poucas fotos boas disponíveis, o que obrigou a tirar dois recortes da mesma foto.
- **As fotos não são do grupo**, como discutido na Seção 2.1.

8. Como reproduzir

O repositório traz o conjunto de imagens já preparado, então basta:

```
pip install opencv-python numpy matplotlib reportlab
python src/main.py
```

que roda o pipeline inteiro — preparo, extração, agrupamento e figuras — em cerca de dez segundos. Para partir das fotos originais, rode antes `python src/baixar_imagens.py`. Os módulos são independentes e podem ser rodados um a um:

Arquivo	O que faz
<code>src/baixar_imagens.py</code>	baixa as fotos candidatas do Wikimedia Commons
<code>src/creditos.py</code>	reconstrói os créditos casando o hash de cada arquivo
<code>src/preparar_imagens.py</code>	RGB $\rightarrow$ cinza e recorte em 512×512
<code>src/filtros.py</code>	o banco de sete filtros e a pirâmide gaussiana
<code>src/extrair.py</code>	médias por janela e o descritor de 24 dimensões
<code>src/agrupar.py</code>	k-médias, k-means++, silhueta, pureza, PCA
<code>src/visualizar.py</code>	todas as figuras deste relatório

Referências

1. Gabor, D. *Theory of communication*. Journal of the IEE, 1946.
2. Jain, A. K.; Farrokhnia, F. *Unsupervised texture segmentation using Gabor filters*. Pattern Recognition, v. 24, n. 12, 1991.
3. Randen, T.; Husøy, J. H. *Filtering for texture classification: a comparative study*. IEEE TPAMI, v. 21, n. 4, 1999.
4. Varma, M.; Zisserman, A. *A statistical approach to texture classification from single images*. IJCV, v. 62, 2005.
5. Arthur, D.; Vassilvitskii, S. *k-means++: the advantages of careful seeding*. SODA, 2007.