

Agrupamento de texturas urbanas com filtros orientados em três escalas

vitormcumim

Visão Computacional — Trabalho 1 (versão resumida) · setembro de 2026

código: <https://github.com/vitormcumim/textura-urbana>

Resumo

Sete filtros de textura — quatro Gabor orientados a 0°, 45°, 90° e 135°, dois detectores de borda e um filtro circular — são aplicados em três escalas de uma pirâmide gaussiana. A média das respostas dentro de uma janela descreve cada região por um vetor de 24 dimensões, e um k-médias euclidiano agrupa os vetores próximos. Sobre 40 recortes de 512×512 em tons de cinza, de oito materiais urbanos, o método forma grupos visualmente coerentes (pureza 0,53) e, aplicado janela a janela, separa dentro de uma mesma imagem coisas como o rejunte e a face da pedra.

1. O problema

Duas regiões de uma imagem em cinza podem ter o mesmo histograma e ainda assim serem visivelmente diferentes: uma parede de tijolos e um trecho de asfalto podem ter o mesmo brilho médio, mas a parede tem linhas horizontais fortes e o asfalto não tem direção nenhuma. Textura é essa diferença — como a intensidade varia no espaço, em que direção e em que tamanho.

A receita clássica para medir isso é passar a imagem por filtros sintonizados em orientações e frequências diferentes e ver quanta energia cada um capta. É o que este trabalho faz, sem nenhum aprendizado de máquina: os filtros são fixos e projetados analiticamente, e o agrupamento é um k-médias de vinte linhas.

2. As imagens

São **40 imagens** de 512×512 pixels em tons de cinza, oito materiais urbanos com cinco imagens cada: asfalto, brita, calçada, concreto, madeira, paralelepípedo, telha e tijolo. As fotos vieram do Wikimedia Commons sob licenças livres, foram convertidas para cinza pela fórmula da ITU-R BT.601 ($Y = 0,299R + 0,587G + 0,114B$) e recortadas em blocos de 512×512 sem sobreposição. Autor e licença de cada foto estão em `fotos_originais/creditos.csv`.

Uma ressalva: o enunciado pede fotos tiradas pelo próprio grupo, e estas não são.

3. Os filtros e as escalas

O banco tem sete filtros de 15×15 pixels:

- **quatro Gabor de fase par** (uma onda cosseno vezes uma gaussiana) a 0°, 45°, 90° e 135°. A fase par tem um lobo central, então é um detector de **linha** — cobre as quatro orientações pedidas no enunciado;
- **dois Gabor de fase ímpar** (onda seno) a 0° e 90°. Sendo antissimétricos, detectam **borda**, não linha. Servem para diferenciar texturas que têm a mesma orientação dominante mas estrutura diferente;
- **um filtro circular**, o Laplaciano da gaussiana. É isotrópico — sua resposta em frequência é um anel — e responde a granulação sem direção preferida. É ele que caracteriza asfalto e brita.

Todos têm média zero, então nenhum responde a brilho constante: só a variação importa.




Figura 1. Os sete filtros. Em cima o núcleo 15×15 (vermelho positivo, azul negativo); embaixo o módulo da resposta em frequência, onde cada Gabor aparece como um par de lobos na direção correspondente e o circular como um anel.

Para o multiescala, o enunciado permite dois caminhos; escolhemos o mais barato, que é manter os filtros do mesmo tamanho e encolher a imagem. A pirâmide gaussiana suaviza e pega um pixel a cada dois, dando níveis de 512×512, 256×256 e 128×128. Como o filtro continua 15×15, no nível 2 ele enxerga uma vizinhança quatro vezes maior da imagem original.

Sete filtros em três escalas dão **21 mapas de resposta** por imagem. De cada um toma-se o valor absoluto, porque uma barra clara e uma barra escura são a mesma textura — sem retificar, a média da janela daria quase zero nos dois casos.




Figura 2. Módulo da resposta dos sete filtros nas três escalas, para um recorte de parede de tijolos. As juntas horizontais acendem no filtro "par 0" e quase somem no "par 90"; o circular responde à granulação da superfície do tijolo.

4. O vetor de 24 dimensões

O descritor de uma região é a **média de cada mapa dentro da janela**, o que dá 21 números. Usar esses 21 números crus não funciona bem: eles crescem com o contraste da foto, e a distância euclidiana passa a medir *quanto contraste a imagem tem* em vez de *que textura ela é* — a mesma parede no sol e na sombra vira dois grupos.

A correção é separar as duas coisas. Cada escala vira oito números: as **sete frações** $r_i / (r_1 + \dots + r_7)$, que dizem como a energia se reparte entre as orientações e o filtro circular (a *forma* da assinatura, invariante a contraste), e o **log da energia total** daquela escala (o *quanto* de textura existe ali). Três escalas × oito números = **24 dimensões**. Na prática essa mudança levou a pureza de 0,40 para 0,53.

O mesmo cálculo serve nas duas granularidades: com a imagem inteira como janela, sai um vetor por imagem, usado para agrupar as 40; com janelas de 64×64 andando de 32 em 32 pixels, saem 225 vetores por imagem, usados para segmentar por dentro.

5. Agrupamento

O k-médias é euclidiano, com centroides iniciais sorteados entre as próprias amostras, semente fixa e oito reinicializações, ficando com a de menor inércia. Antes, cada dimensão passa por z-score: as frações vivem entre 0 e 1 e a energia logarítmica vale alguns inteiros, então sem normalizar a distância ignoraria as dimensões de orientação.

Com $k = 8$, o número de materiais, a pureza é **0,53** — a fração de imagens que caiu no material majoritário do seu grupo.

As 40 imagens agrupadas por textura (cor da moldura = grupo)




Figura 3. As 40 imagens organizadas pelos oito grupos encontrados. A cor da moldura indica o grupo.

Grupo	n	O que reuniu
G0	3	veio de madeira horizontal, listras finas e alongadas
G1	11	granulado grosso e sem direção: brita, concreto granulado, pedra rugosa
G2	1	tapume claro de ripas verticais
G3	5	granulação fina e uniforme: asfalto, concreto
G4	3	quase sem textura: concreto liso e ladrilho em xadrez
G5	2	superfícies lisas cortadas por poucas juntas retas
G6	3	estrias diagonais finas e repetidas: telha em fiada inclinada
G7	12	blocos separados por juntas claras: tijolo, calçada, telha, pedra

A pureza de 0,53 esconde um comportamento que a figura deixa claro: **os grupos são coerentes como textura mesmo quando não coincidem com o material**. G1 junta as quatro britas com concretos granulados, paralelepípedos rugosos e até uma parede de tijolo áspera — todos são granulação grossa isotrópica, e o filtro circular os vê como a mesma coisa. G7 junta tijolo, calçada em blocos, telha em fiada e pedra rachada, que são todos "blocos separados por juntas claras". Já as telhas se partiram em dois grupos: as de fiada inclinada foram para G6 e as empilhadas de frente para G7, porque são duas texturas bem diferentes que por acaso têm o mesmo nome.

Vale registrar uma observação que apareceu ao comparar esta versão com a completa, que usa inicialização k-means++: a versão completa chega a uma pureza melhor (0,58) com uma inércia **pior** (218,2 contra 210,5). Ou seja, o agrupamento que o k-médias considera melhor pelo seu próprio critério não é o que mais concorda com as etiquetas dos materiais. A pureza não é o que está sendo otimizado.

6. Segmentação dentro das imagens

Rodando o mesmo k-médias sobre as 9.000 janelas de 64×64 de todas as imagens, com k = 6, cada janela recebe a cor do grupo mais próximo.




Figura 4. Segmentação por textura: acima as imagens originais, abaixo o mapa de grupos sobreposto. Em madeira_00 as frestas entre as ripas saem em verde, separadas das faces; em paralelepipedo_00 o rejunite sai em azul-esverdeado e as faces das pedras em vermelho; em tijolo_00 as juntas de argamassa se separam dos tijolos.

Este é o resultado mais fácil de auditar a olho: as regiões que o método separa são as que uma pessoa apontaria. O mapa é grosseiro por construção — a menor unidade é uma janela de 64×64, então os limites saem em degraus de 32

pixels.

7. Limitações

- **Sem invariância a rotação:** girar a foto 45° muda o descritor por completo, consequência direta de usar orientações fixas.
- **Sem invariância a escala de aquisição:** as três escalas cobrem uma faixa de 4×; a mesma parede fotografada de perto e de longe pode cair em grupos diferentes.
- **k escolhido à mão:** adotamos $k = 8$ por ser o número de materiais, que é informação externa ao método.

8. Como rodar

```
pip install opencv-python numpy matplotlib  
python simples/textura_simples.py
```

Um único arquivo, `simples/textura_simples.py`, faz tudo o que está descrito aqui e escreve as duas figuras em `simples/saida/`. A versão completa do trabalho está em `src/`, com o download e o preparo das fotos, escolha de k por silhueta, projeção PCA e mais figuras.

Referências

1. Jain, A. K.; Farrokhnia, F. *Unsupervised texture segmentation using Gabor filters*. Pattern Recognition, v. 24, n. 12, 1991.
2. Randen, T.; Husøy, J. H. *Filtering for texture classification: a comparative study*. IEEE TPAMI, v. 21, n. 4, 1999.
3. Varma, M.; Zisserman, A. *A statistical approach to texture classification from single images*. IJCV, v. 62, 2005.